

New perspectives on archiving practices in language documentation

Niko Partanen, Michael Rießler & Marina Fedina



Who am I?

- I work currently as a visiting researcher in LATTICE laboratory, Paris
- I'm a linguist working with Uralic languages (minority languages in Russia)
- I'm one of the PI's in the project [Language Documentation meets Language Technology: The Next Step in the Description of Komi](#)
- I've been working with language documentation materials for last five years
- Other important collaborators are Michael Rießler (Freiburg), Rogier Blokland (Uppsala) and Marina Fedina (Syktyvkar)
- We try to adhere to field's best practices, but also foster more informal collaboration between different research projects

Talk structure

- Few words on language documentation and general context
- Research projects
- Our data
- Archive interaction
- “Ideal workflow”

Slides available in: nikopartanen.github.io/IASA2017

Language documentation

- Language documentation ... concerned with the methods, tools, and theoretical underpinnings for compiling a representative and lasting **multipurpose** record of a language or one of its varieties ([Himmelman 1998](#); [Himmelman 2012](#))
- Usually focus on endangered languages
- Produces large amounts of linguistically annotated multimedia
- Traditionally lots of focus in metadata
 - Essential for linguistic research as well
 - The cultural context of recorded activities









00:00:29.726

Selection: 00:00:29.728 - 00:00:32.233 2505

☐ Selection Mode☐ Loop Mode

Grid Text Subtitles Lexicon Comments Recognizers Metadata Controls

▼ orth@JAI-M-1939 [671]

> Nr	Annotation	Begin Time	End Time	Duration
1	Пожняысь, Пожня, Пожня, Пожня сиктысь, да .	00:00:29.728	00:00:32.233	00:00:02.505
2	Да, уджалі .	00:00:40.165	00:00:40.953	00:00:00.788
3	Сійо вёлі	00:00:44.690	00:00:45.958	00:00:01.268
4	квайтымын	00:00:46.643	00:00:47.690	00:00:01.047
5	ётикёд воын, навернэ,	00:00:47.890	00:00:49.283	00:00:01.393
6	или квайтымынёд,	00:00:49.418	00:00:51.090	00:00:01.672
7	навернэ, ээ .	00:00:51.590	00:00:53.028	00:00:01.438
8	Ыхы, квайтымынёд воын, ме вёлі мёд курсын велэдчи	00:00:53.633	00:00:57.271	00:00:03.638
9	пединститутын, квайтымынёд воын, тóвнас .	00:00:57.655	00:01:00.071	00:00:02.416
10	Воліс татчó .	00:01:00.950	00:01:02.135	00:00:01.185
11	Да .	00:01:02.510	00:01:03.080	00:00:00.570

kpv_izva20140404lgusevJA.wav

00:00:30.000 00:00:31.000 00:00:32.000 00:00:33.000 00:00:34.000 00:00:35.000

Unsupported compression type for Wave file



Timeline view showing multiple tracks and their alignment:

- ref@NTP-M-1986 [223]
- orth@NTP-M-1986 [223]
- word@NTP-M-1986 [1416]
- ft-eng@NTP-M-1986 [223]
- ft-rus@NTP-M-1986 [223]
- ref@JAI-M-1939 [671]
- orth@JAI-M-1939 [671]
- word@JAI-M-1939 [5507]
- ft-eng@JAI-M-1939 [671]
- ft-rus@JAI-M-1939 [671]

Timeline segments and their content:


- 00:00:30.000 - 00:00:31.000: kpv_izva20140404lgusevJA-b-004
- 00:00:31.000 - 00:00:32.000: kpv_izva20140404lgusevJA-b-004
- 00:00:32.000 - 00:00:33.000: kpv_izva20140404lgusevJA-b-004
- 00:00:33.000 - 00:00:34.000: kpv_izva20140404lgusevJA-b-004
- 00:00:34.000 - 00:00:35.000: kpv_izva20140404lgusevJA-b-004

Transcription details for the selected segment (00:00:30.000 - 00:00:35.000):

Track	Text
orth@JAI-M-1939 [671]	Пожняысь, Пожня, Пожня, Пожня сиктысь, да .
word@JAI-M-1939 [5507]	Пожн . Да .
ft-eng@JAI-M-1939 [671]	From Pozhna, Pozhna, Pozhna village, yes.
ft-rus@JAI-M-1939 [671]	Из Пожня, Пожня, Пожня, из деревни Пожня, да .

Ižva Komi Documentation Project (1 & 2)

- Funded by Kone Foundation
 - Collaborators in Uppsala, Freiburg, Syktyvkar and Paris
 - [First project](#) in 2014-2016, the [current](#) in 2017-2019
 - Data archived (mostly) into [TLA in Nijmegen](#)
-
- Initial focus in data collection and building the corpus
 - Now we are working with language technology, corpus maintenance and improving the accessibility of the data, also conducting research on the data





Data availability

- Close collaboration with local institutions and speakers in Russia
- Emphasis in easily shared, rather neutral, still generally interesting topics
 - Biographies, local history, experiences on language use and learning, narratives etc.
 - Central point has been to produce data that in principle can be shared
 - However, with personal data situation is never that simple
- Different users have different needs
 - One interface cannot satisfy all, but some combination probably goes far
 - Raw data access essential so people can do what they want
- Archive is the most important component in the infrastructure we use
 - Nothing else comes even close with long term data preservation



CONTENT SEARCH



MANAGE ACCESS



REQUEST ACCESS



VIEW



BOOKMARK



CITATION



DOWNLOAD



VERSION INFO

URL: https://corpus1.mpi.nl/media-archive/donated_corpora/Permic_Varieties/IKDP/Annotations/kpv_izva20160627-02.eaf

Handle URI: <https://hdl.handle.net/1839/EF58E573-438A-4425-A837-16C8F7F3C79B>

Internal Node ID: MPI2274086#

Node type: Written Resource

Format: text/x-eaf+xml

File size: 10114 bytes

Last modified: Sat Dec 03 18:51:21 CET 2016

MD5 Check sum: unknown

Access Info

The resource can be viewed by clicking the "view" button and checking the permissions.

General Accessibility: Access to the resource is possible
Currently accessible to user anonymous: no

Applicable License Agreement(s)

No licenses required for this resource.

Rights

All resources in this archive are Copyright © of their respective owners. The reproduction or distribution of the resource without the permission of the copyright holder is prohibited, unless the copyright holder has given explicit permission to do so. For more information, contact information or contact corpman@mpi.nl.

- Main archival versions in TLA
- Still being updated
- Serves primarily as a long-term storage
- Data available upon request
- Handles get assigned in the upload process etc.

- Contains also good search tool, TROVA
- Metadata gets indexed

- Not impossible to maintain ...
... but clicky!
- Clicking hundreds of times makes updating tedious and error-prone

- ⊕ kpv_izva20150706-02-b
- ⊕ kpv_izva20150706-03-b
- ⊕ kpv_izva20150707-01-b
- ⊕ kpv_izva20150707-02-b
- ⊕ kpv_izva20150707-03-b
- ⊕ kpv_izva20150707-04-b
- ⊕ kpv_izva20160619-03
- ⊕ kpv_izva20160619-04
- ⊕ kpv_izva20160619-06
- ⊕ kpv_izva20160619-07
- ⊕ kpv_izva20160620-01
- ⊕ kpv_izva20160620-03
- ⊕ kpv_izva20160620-06
- ⊕ kpv_izva20160620-07
- ⊕ kpv_izva20160622-01
- ⊕ kpv_izva20160622-02
- ⊕ kpv_izva20160622-03
- ⊕ kpv_izva20160622-04
- ⊕ kpv_izva20160622-05-a
- ⊕ kpv_izva20160622-05-b
- ⊕ kpv_izva20160623-01
- ⊕ kpv_izva20160623-02
- ⊕ kpv_izva20160623-04
- ⊕ kpv_izva20160623-05
- ⊕ kpv_izva20160623-06
- ⊕ kpv_izva20160624-01
- ⊕ kpv_izva20160624-02
- ⊕ kpv_izva20160624-03
- ⊕ kpv_izva20160625-02
- ⊕ kpv_izva20160625-03
- ⊕ kpv_izva20160626-01
- ⊕ kpv_izva20160626-06
- ⊕ kpv_izva20160626-08
- ⊕ kpv_izva20160626-09
- ⊕ kpv_izva20160627-01
- ⊕ kpv_izva20160627-02
- ⊕ **kpv_izva20160627-02.eaf**
- ⊕ kpv_izva20160627-02.mp4
- ⊕ kpv_izva20160627-02.wav
- ⊕ kpv_izva20160627-02

Substring SearchSingle Layer SearchMultiple Layer Search

Types: ☒ EAF (498) ☒ Text (9) ☒ HTML (1)

Domain: Permic Varieties

Find

Ready Found 891 hits in 852 annotations

Action: **Show Concordance View** Page: Hit 1 - 15 of 891 hits

Context Size: Font: **Lucida Grande** ☐ Show Info Balloons

но татõн сійõ яранъяс из вõв нõшта и **кõр** видзисьõсь татõн **кõр**ьясõõ видзõны коркõ дажõ приколхозõ видзисны а сейсятпервõй годах ме помнита **кõр** н

но татõн сійõ яранъяс из вõв нõшта и **кõр** видзисьõсь татõн **кõр**ьясõõ видзõны коркõ дажõ приколхозõ видзисны а сейсятпервõй годах ме помнита **кõр** на вõлi **сейс**етьпервый г

кõр видзисьõсь татõн **кõр**ьясõõ видзõны коркõ дажõ приколхозõ видзисны а сейсятпервõй годах ме помнита **кõр** на вõлi **сейс**етьпервый годах на **кõр** на мян татын вõлi именна важгортсаысь??? о-о-о тундраа из ветлыны най

õны коркõ дажõ приколхозõ видзисны а сейсятпервõй годах ме помнита **кõр** на вõлi **сейс**етьпервый годах на **кõр** на мян татын вõлi именна важгортсаысь??? о-о-о тундраа из ветлыны найõста татын и олiсны

а танi кыдзи танi яран, танi яранъяс тшõтш вõйтти вõлiсны? мм да вõлi? а **кõр**ьяс кыдз, кõнi видзисны, вõрын?

вõйтти яранъяс татi ветлõмаõсь **кõр**ьясõн а мян танi **Важгортас** асланым яранъяс вõлiны **кõр**ьясõõ, **кõр**ьясõõ видзисны приколхозõ тан мян видзис

вõйтти яранъяс татi ветлõмаõсь **кõр**ьясõн а мян танi **Важгортас** асланым яранъяс вõлiны **кõр**ьясõõ, **кõр**ьясõõ видзисны приколхозõ тан мян видзисны **кõр**ьясõõ вõлi вõлi вõлi вõлi вõлi ме сэйсятьпътõй

вõйтти яранъяс татi ветлõмаõсь **кõр**ьясõн а мян танi **Важгортас** асланым яранъяс вõлiны **кõр**ьясõõ, **кõр**ьясõõ видзисны приколхозõ тан мян видзисны **кõр**ьясõõ вõлi вõлi вõлi вõлi вõлi вõлi ме сэйсятьпътõй годин вõл

и́н а мян танi **Важгортас** асланым яранъяс вõлiны **кõр**ьясõõ, **кõр**ьясõõ видзисны приколхозõ тан мян видзисны **кõр**ьясõõ вõлi вõлi вõлi вõлi вõлi вõлi ме сэйсятьпътõй годин вõлõм таысь муõна сiсьздз

яранъяс да **кõр** видзõмаõсь, **кõр**ьясõõ мян тожõ овлывл- ??? вõр сюра ягын шуасны сiйõс

яранъяс да **кõр** видзõмаõсь, **кõр**ьясõõ мян тожõ овлывл- ??? вõр сюра ягын шуасны сiйõс

из вõв нõшта и **кõр** видзисьõсь татõн **кõр**ьясõõ видзõны

и **кõр** видзисьõсь татõн **кõр**ьясõõ видзõны коркõ дажõ приколхозõ

сейсятпервõй годах ме помнита **кõр** на вõлi **сейс**етьпервый годах

вõлi **сейс**етьпервый годах на **кõр** на мян татын вõлi

Combined

min



Text: -

14 ▼

Lucida Grande

☒ Comments overlay

word@VVJ-F-1

MM

да

приколхозё тан мян видзисны кӧръяссӧ

a

приколхоз тан миян видзисны кӧръяссӧ

www.videocorpora.ru



KOMI MEDIA COLLECTION

[ABOUT THE PROJECT](#) [SEARCH](#) [WHOLE MEDIA COLLECTION](#) [OUR TEAM](#) [MAP](#) [INSTRUCTIONS](#) [CONTACTS](#)

- Trilingual website
- Especially designed for the speakers
- Individuals on the video have also received their own copies
- Take down policy if requested



- Data stored on a server in Syktyvkar
- Matches closely the files in TLA
- Has to be manually updated
 - We are working with automatization
- Currently no explicit links to the archive

© 2016 All rights reserved.

Rogier Blokland, Vasilij Chuprov, Dmitrij Levchenko, Maria Fedina, Marina Fedina, Niko Partanen, Michael Rießler. 2016. Komi media collection. Syktyvkar: FU-Lab.

URL: <http://videocorpora.ru>

Александр Юрьевич Терентьев



И сыа тшӧтш сетэ тэныд вын водзэ сідз мунны, мый



АЈТ-М-1992(00:07:10 - 00:07:14)

KPV: И сыа тшӧтш сетэ тэныд вын водзэ сідз мунны, мый

RUS: И это тоже дает тебе силы двигаться дальше, что

ENG: And it also gives you strenghts to go further, that



АЈТ-М-1992(00:07:14 - 00:07:17)

KPV: мӧдъяс велэдэны, а мыля ми асьнум асьнумес ог велэдэ,

RUS: другие изучают, а почему мы сами себя не изучаем,

ENG: others study, and why we ourselves don't study ourselves,



АЈТ-М-1992(00:07:17 - 00:07:19)

KPV: колэ тшӧтш сіе вӧчны.

RUS: это тоже надо делать.

Show Timeline



Report errors

Etsi

virkkeen

sisältä

corp.csc.fi

Konkordanssi:

osumia sivulla: 25

järjestä korpuksen sisällä: järjestämätön

Tilastoja:

laske tilastot tämän perusteella: sana

☐ Näytä sanakuva

☐ Näytä kartta

Konkordanssi

Tilastoja

Sanakuva

Kartta

Nimiluokittelu

Tuloksia: 48

«

<

1

2

>

»

Siirry sivulle

/ 2

Näytä konteksti

FINN TREE BANK 3: EURO PARL

Kysymme, tiedätkö, mikä **kissa on**, ja vastaus on: kissa on tiikeri, joka on neuvotellut valtiovarainvaliokunnan kanssa.

Kysymme, tiedätkö, mikä kissa on, ja vastaus on: **kissa** on tiikeri, joka on neuvotellut valtiovaraivaliokunnan kanssa.

Olen myös vakuuttunut siitä, että teidän on oltava vihdoin rohkea ja nostettava **kissa** pöydälle.

Meidän on lakattava kiertämästä asioita kuin **kissa** kuumaa puuroa ja nostettava vihdoinkin esiin todelliset ongelmat, jotka liittyvät apartheidin jälkei

Eyadéma leikkii kanssamme **kissa** ja hiirtä.

Tämä olisi tae sekä Yhdysvalloille että Irakille, ja se estäisi **kissa** ja hiiri -leikit.

Arvoisa puhemies, uskoakseni me leikimme nyt **kissa** ja hiiri -leikkiä parlamentissa ja tämä on kamalaa, aivan kamalaa demokratian kannalta!

n aseistariisunnan puolesta, ei ole epäilystäkään siitä, että eikö Saddam Hussein jatkaisi entiseen tapaan **kissa** ja hiiri -leikkiään YK:n kanssa loputtomiin.

Meidän on aika toimia IMO:ssa yhdessä ja vaatia loppua tällaiselle **kissa** ja hiiri -leikille, jollaiseksi kansainvälinen merenkulku näyttää muuttuneen.

Varsinkin turvastandardimietinnön valmistelu on ollut aika ajojn melkoista **kissa** ja hiiri -leikkiä komission ja neuvoston kanssa.

Muuten saattaa syntyä kuva, että Dov Weisglass oli oikeassa ja hänen ainoa virheensä oli nostaa **kissa** pöydälle.

Kiinan tapauksessa ongelmaa ei kuitenkaan voida kiertää kuin **kissa** kuumaa puuroa.

lexander, eurooppalaiset ansaitsevat enemmän kuin unionin puheenjohtajavaltion ja sen 24 kumppanin **kissa** ja hiiri -leikin unionin tulevaisuuden kannalta merkittävän Eurooppa-neuvoston kokouksen aatton

nitetä huomiota kalavaroihin, on sama kuin täyttäisi kultakalamaljan puhtaalla vedellä vasta sitten, kun **kissa** on jo ehtinyt napata ja syödä kultakalan.

skirjan " hyödyntäminen olennaisena osana " Euroopan perustuslakia " on ollut juonena jo pitkään tässä **kissa** ja hiiri -leikissä.

attomat kuluttajat voivat ostaa leluja lapsilleen hyväuskoisina ja aavistamatta lainkaan, että esimerkiksi **kissa** on voitu nylkeä elävältä käytettäväksi samaisessa lelussa.

sanonnoille, kuten de hond in de pot vinden (keksiä koirasta illallinen) tai de kat in de zak kopen (ostaa **kissa** säkissä), se tarkoittaa, että haluamme suojella meille rakkaita eläimiä emmekä voi hyväksyä, että

ttävä skottilaisen - joskaan ei poliittisen - kollegani Struan Stevensonin näkemykseen toteamalla, että se **kissa** , joka olisi nostettava pöydälle, ovat ne huonot hinnat, joita maanviljelijät joutuvat yhä sietämään, i

Emme saa enää sallia tämän **kissa** ja hiiri -leikin jatkumista.

Kuten Deng Xiaopingilla oli tapana sanoa: " Ei ole väliä, onko **kissa** musta vai valkoinen, kunhan se pyydystää hiiriä " .

Toisinaan on erittäin vaikea nähdä, kuka tässä **kissa** ja hiiri -leikissä on kissa ja kuka hiiri.

Toisinaan on erittäin vaikea nähdä, kuka tässä **kissa** ja hiiri -leikissä on **kissa** ja kuka hiiri.

Kriisistä ei päästä yli siten, että laitetaan **kissa** vahtimaan kerma-astiaa!

e, että on harhaa uskoa, että tähän yhteyteen sopii hyvin satu Bremenin soittoniekoista, jossa aasi, koira, **kissa** ja kukko lähtivät suureen maailmaan, koska he uskoivat, että missä tahansa on jotakin parempaa l

Yhdysvallat pitää sitten hauskaa meidän kustannuksellamme niin kuin **kissa** hiiren kanssa: se valittaa Maailman kauppajärjestyön viljatuotteista ja riisistä, ja kun komissio aikoo

«

<

1

2

>

»

Siirry sivulle

/ 2

Korpus

FinnTreeBank 3: EuroParl

Kuvailutiedot
Lisenssi: CC BY 3.0 (CLARIN PUB)
Viittaa korpuksen
Linkki korpuksen Korpissa: urn:nbn:fi:lb-201406021

Tekstin ominaisuudet

tiedoston nimi: EuroParl Corpus/fi-en/fi/ep-00-07-04.txt
luvun otsikko: Vastuuvapaus 1998
puhuja: Camre
alkuperäiskieli: tuntematon
rivinumero: 338

Sanan ominaisuudet

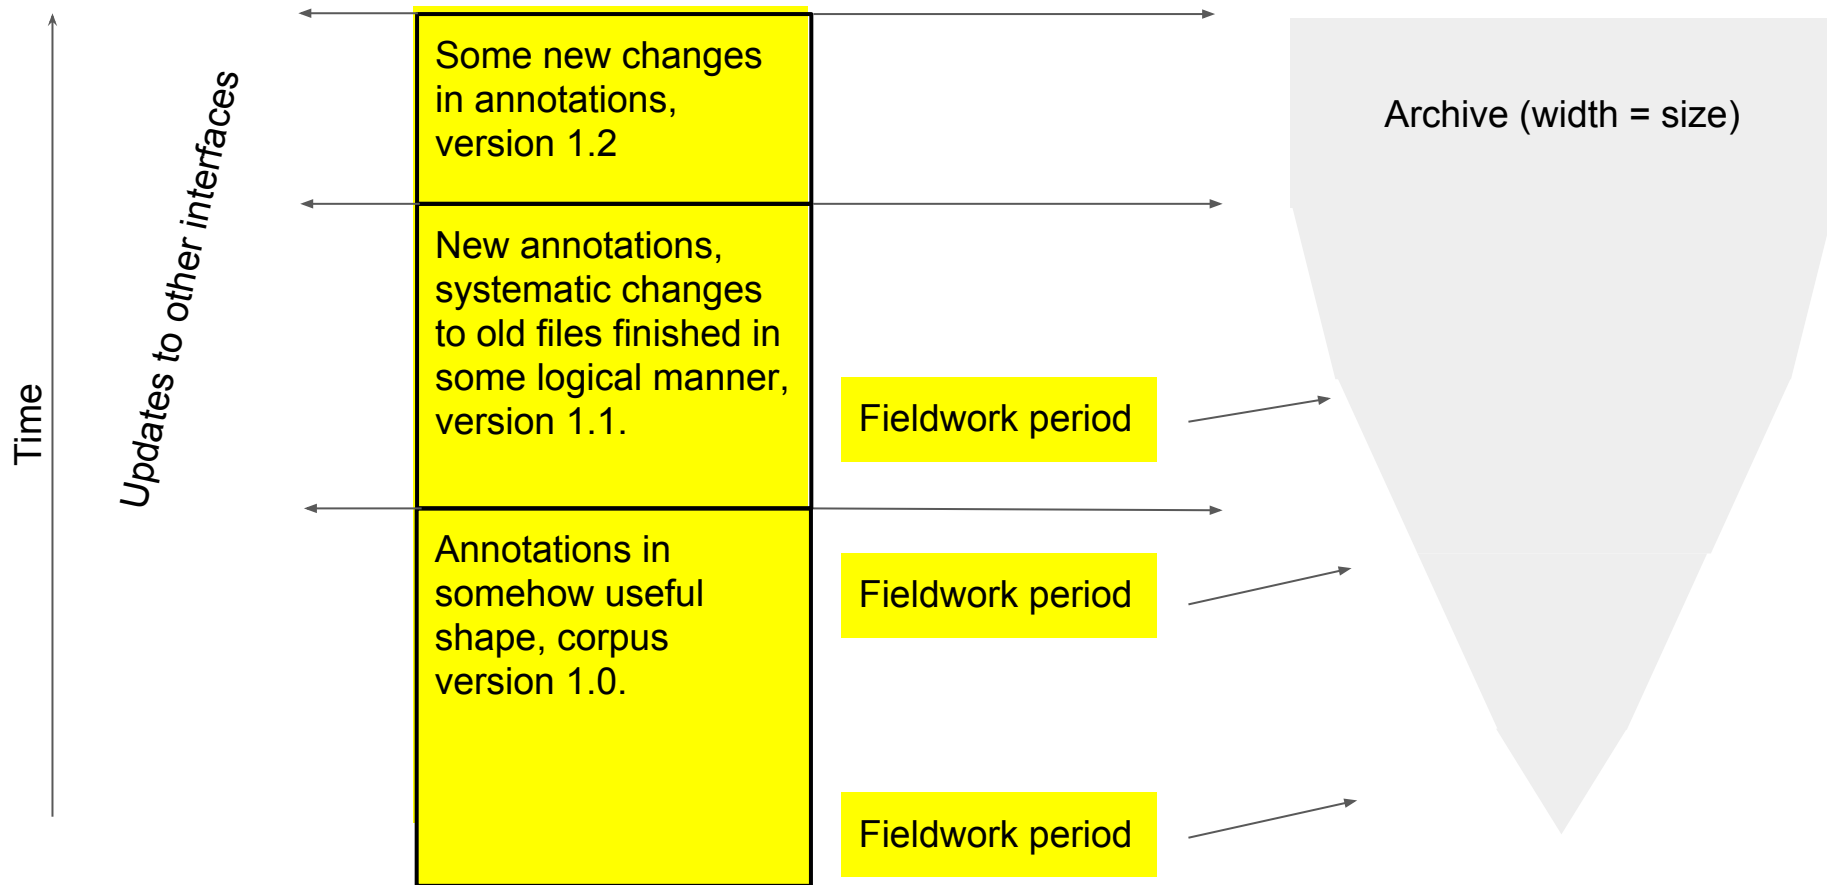
perusmuoto: kissa
perusmuoto (yhdyssanaratjat): kissa
sanaluokka: substantiivi
morfologinen analyysi: N Nom Sg
dependenssisuhde: subjekti

Näytä dependenssipuu

Archive interaction (in an ideal world)

- New audio and video files added roughly once a year
- Once audio and video are archived, the changes into those are exceptional
- There is continuous work going on with annotations
- We use version control (Git) to keep them organized
 - Changes every few days
 - There are usually several larger changes being done
- Ideally the new changed files would be updated in the archive regularly
 - Every half a year?
 - Would correspond to a change in corpus version number

Workflow scheme



Dreaming of API

- At the moment we mainly interact with the archive through specific software
 - Arbil, LAMUS2 etc.
- Works, but is built around the idea that user want to manually do every edit
- We know exactly which files have to be changed and their location in the tree
 - So why do we have to select manually these things again in the interface?
- **Are archives generally even interested about offering APIs to their data?**
- The tasks we need to do are rather modest:
 - Add a file, update a file
 - Change the access level
 - Get information about the files
 - Handles, date of change, MD5, information about number of times accessed etc.
- Data in different interfaces has to be the same!

Thank you!



This work was partially supported by the LATTICE laboratory through a RGNF-CNRS grant.
The research on Ižva Komi has been funded by Kone Foundation.