# New perspectives on archiving practices in language documentation

Niko Partanen, Michael Rießler & Marina Fedina



# Who am I?

- I work currently as a visiting researcher in LATTICE laboratory, Paris
- I’m a linguist working with Uralic languages (minority languages in Russia)
- I’m one of the PI’s in the project Language Documentation meets Language Technology: The Next Step in the Description of Komi
- I’ve been working with language documentation materials for last five years
- Other important collaborators are Michael Rießler (Freiburg), Rogier Blokland (Uppsala) and Marina Fedina (Syktyvkar)
- We try to adhere to field’s best practices, but also foster more informal collaboration between different research projects

# Talk structure

- Few words on language documentation and general context
- Research projects
- Our data
- Archive interaction
- “Ideal workflow”

Slides available at: nikopartanen.github.io/IASA2017

# Language documentation

- Language documentation ... concerned with the methods, tools, and theoretical underpinnings for compiling a representative and lasting **multipurpose** record of a language or one of its varieties (Himmelmann 1998; Himmelmann 2012)
- Usually focus on endangered languages
- Produces large amounts of linguistically annotated multimedia

- Traditionally a great deal of focus on metadata
  - Essential for linguistic research as well
  - The cultural context of recorded activities

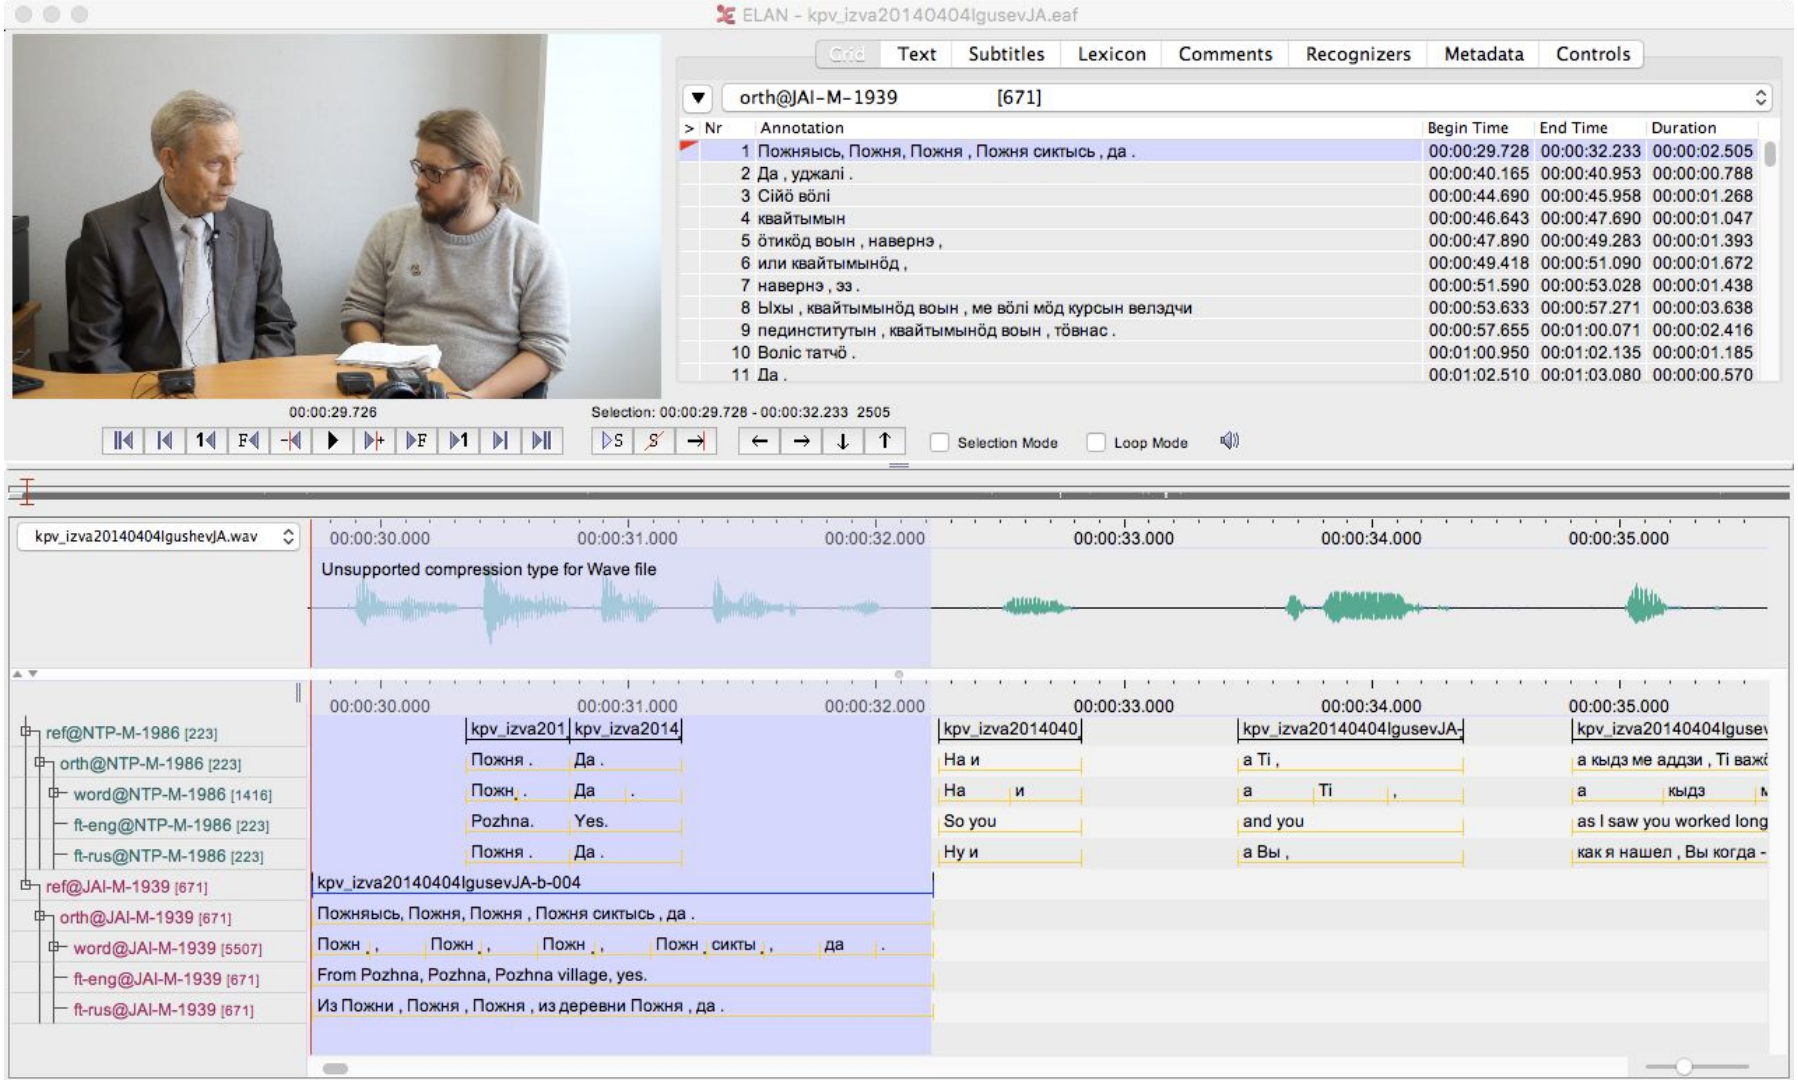
ELAN - kpv_izva20140404lgusevJA.eaf
Text
Subtitles
Lexicon
Comments
Recognizers
Metadata
Controls
orth@JAI-M-1939 [671]
> Nr Annotation Begin Time End Time Duration
1 Пожняысь, Пожня, Пожня , Пожня сиктысь , да . 00:00:29.728 00:00:32.233 00:00:02.505
2 Да , уджалі . 00:00:40.165 00:00:40.953 00:00:00.788
3 Сійӧ вӧлі 00:00:44.690 00:00:45.958 00:00:01.268
4 квайтымын 00:00:46.643 00:00:47.690 00:00:01.047
5 ӧтикӧд воын , наверно , 00:00:47.890 00:00:49.283 00:00:01.393
6 или квайтымынӧд , 00:00:49.418 00:00:51.090 00:00:01.672
7 наверно , эз . 00:00:51.590 00:00:53.028 00:00:01.438
8 Ыхы , квайтымынӧд воын , ме вӧлі мӧд курсын велэдчи 00:00:53.633 00:00:57.271 00:00:03.638
9 пединститутын , квайтымынӧд воын , тӧвнас . 00:00:57.655 00:01:00.071 00:00:02.416
10 Волiс татчӧ . 00:01:00.950 00:01:02.135 00:00:01.185
11 Да . 00:01:02.510 00:01:03.080 00:00:00.570
00:00:29.726
Selection: 00:00:29.728 - 00:00:32.233 2505
Selection Mode
Loop Mode
kpv_izva20140404lgushevJA.wav
Unsupported compression type for Wave file
00:00:30.000
00:00:31.000
00:00:32.000
00:00:33.000
00:00:34.000
00:00:35.000
ref@NTP-M-1986 [223]
orth@NTP-M-1986 [223]
word@NTP-M-1986 [1416]
ft-eng@NTP-M-1986 [223]
ft-rus@NTP-M-1986 [223]
ref@JAI-M-1939 [671]
orth@JAI-M-1939 [671]
word@JAI-M-1939 [5507]
ft-eng@JAI-M-1939 [671]
ft-rus@JAI-M-1939 [671]
kpv_izva201
kpv_izva2014
kpv_izva2014040
kpv_izva20140404lgusevJA-
Пожня .
Да .
На и
а Ti ,
Пожн .
Да .
На и
а Ti ,
а кыдз
Pozhna.
Yes.
So you
and you
as I saw you worked long
Пожня .
Да .
Ну и
а Вы ,
как я нашел , Вы когда -
kpv_izva20140404lgusevJA-b-004
Пожняысь, Пожня, Пожня , Пожня сиктысь , да .
Пожн . , Пожн . , Пожн . , Пожн . сикты . , да .
From Pozhna, Pozhna, Pozhna village, yes.
Из Пожни , Пожня , Пожня , из деревни Пожня , да .

# Iźva Komi Documentation Project (1 & 2)

- Funded by Kone Foundation
- Collaborators in Uppsala, Freiburg, Syktyvkar and Paris
- First project in 2014-2016, current in 2017-2019
- Data archived (mostly) in TLA in Nijmegen

- Initial focus in data collection and building the corpus
- Now we are working with language technology, corpus maintenance and improving the accessibility of the data, also conducting research on the data

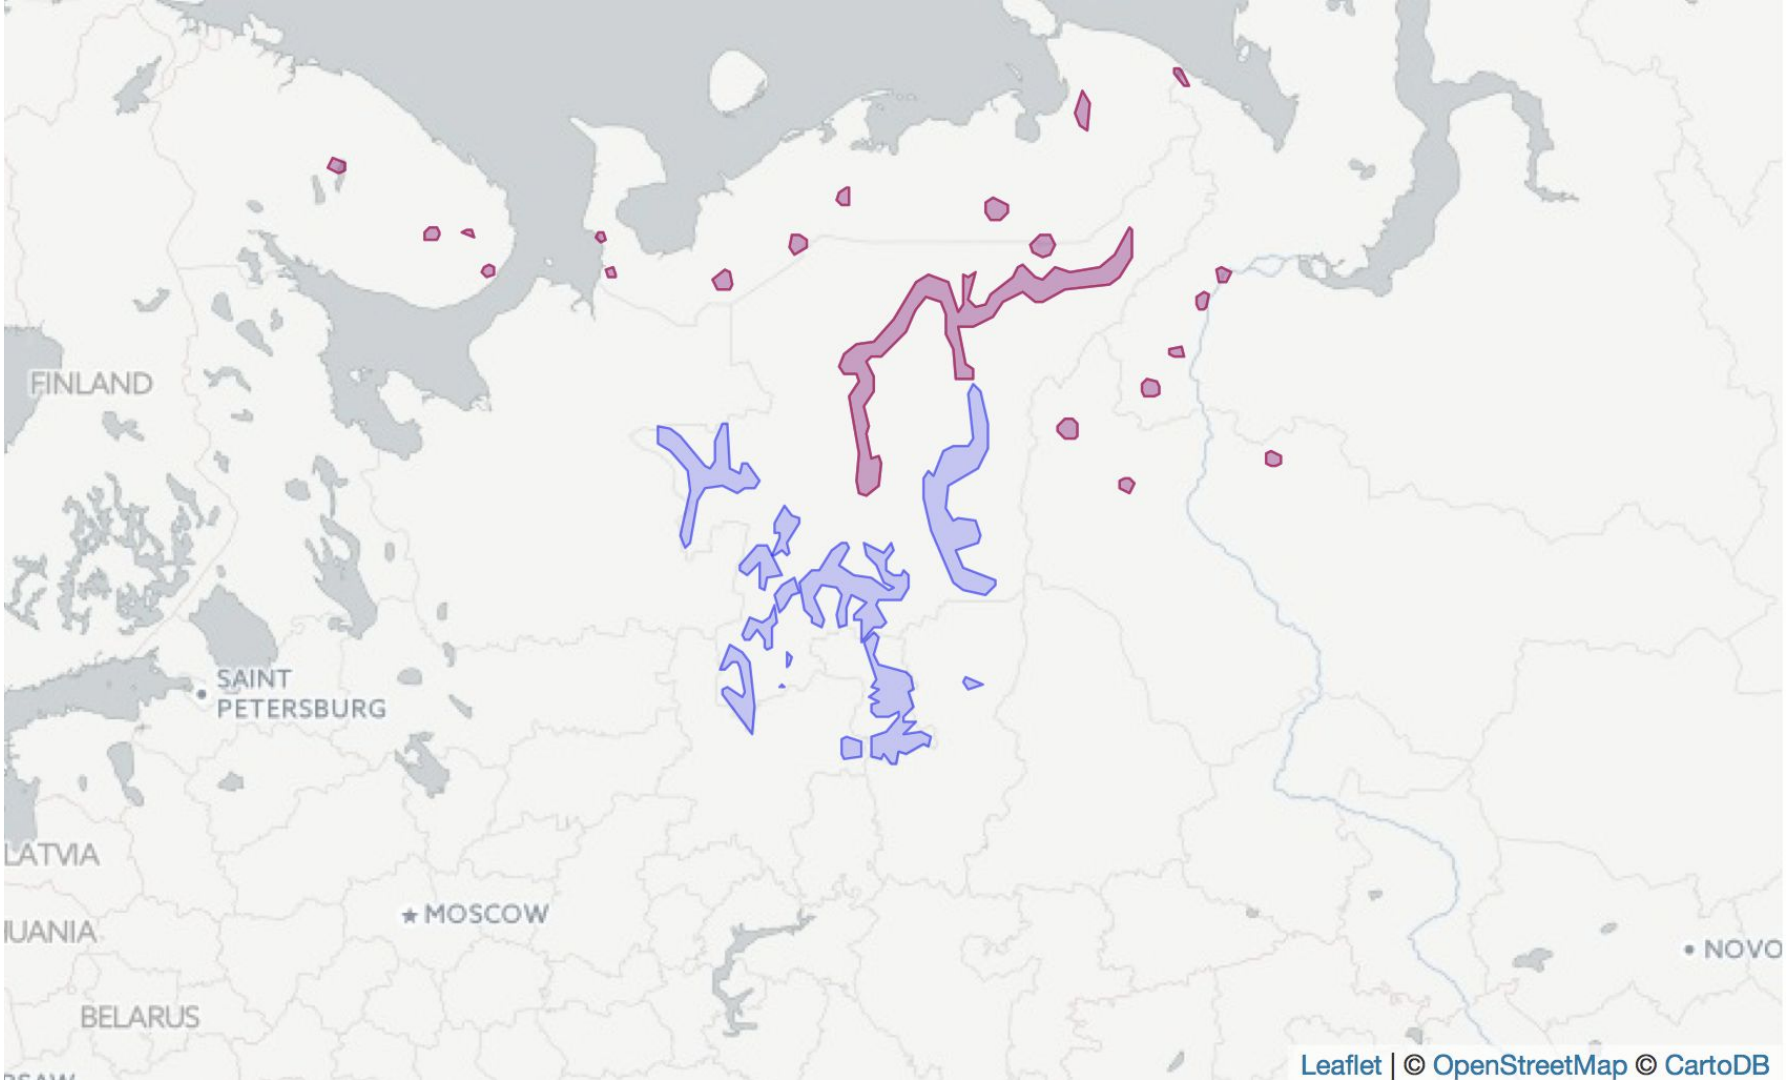
FINLAND
SAINT PETERSBURG
LATVIA
MOSCOW
BELARUS
NOVO
Leaflet | © OpenStreetMap © CartoDB

# Data availability

- Close collaboration with local institutions and speakers in Russia
- Emphasis on easily shared, rather neutral, still generally interesting topics
  - Biographies, local history, experiences on language use and learning, narratives, etc.
  - Central point has been to produce data that, in principle, can be shared
  - However, when dealing with personal data the situation is never that simple

- Different users have different needs
  - One interface cannot satisfy all, but some combination probably goes far
  - Raw data access essential so people can do what they want with it

- Archive is the most important component in the infrastructure we use
  - Nothing else comes even close in terms of long-term data preservation

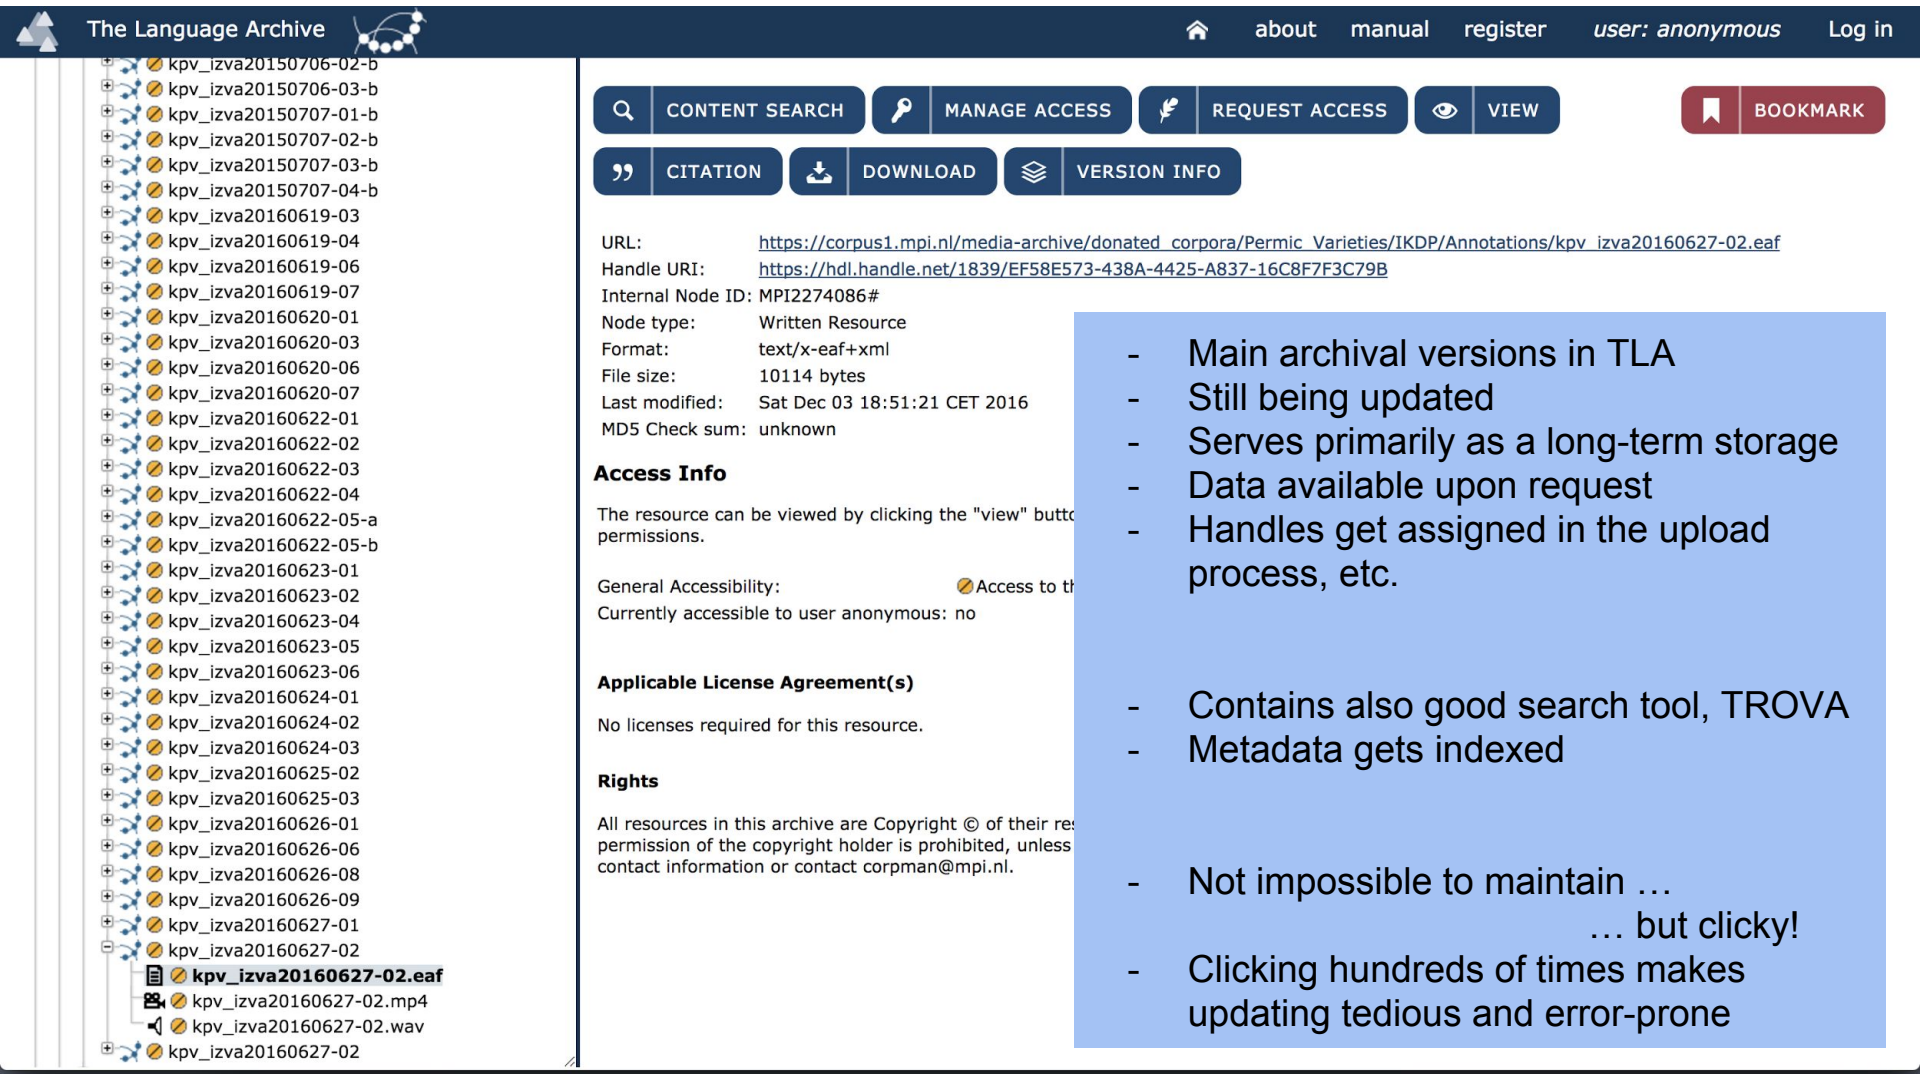
The Language Archive
about
manual
register
user: anonymous
Log in
kpv_izva20150706-02-b
kpv_izva20150706-03-b
kpv_izva20150707-01-b
kpv_izva20150707-02-b
kpv_izva20150707-03-b
kpv_izva20150707-04-b
kpv_izva20160619-03
kpv_izva20160619-04
kpv_izva20160619-06
kpv_izva20160619-07
kpv_izva20160620-01
kpv_izva20160620-03
kpv_izva20160620-06
kpv_izva20160620-07
kpv_izva20160622-01
kpv_izva20160622-02
kpv_izva20160622-03
kpv_izva20160622-04
kpv_izva20160622-05-a
kpv_izva20160622-05-b
kpv_izva20160623-01
kpv_izva20160623-02
kpv_izva20160623-04
kpv_izva20160623-05
kpv_izva20160623-06
kpv_izva20160624-01
kpv_izva20160624-02
kpv_izva20160624-03
kpv_izva20160625-02
kpv_izva20160625-03
kpv_izva20160626-01
kpv_izva20160626-06
kpv_izva20160626-08
kpv_izva20160626-09
kpv_izva20160627-01
kpv_izva20160627-02
kpv_izva20160627-02.eaf
kpv_izva20160627-02.mp4
kpv_izva20160627-02.wav
kpv_izva20160627-02
CONTENT SEARCH
MANAGE ACCESS
REQUEST ACCESS
VIEW
BOOKMARK
CITATION
DOWNLOAD
VERSION INFO
URL: https://corpus1.mpi.nl/media-archive/donated_corpora/Permic_Varieties/IKDP/Annotations/kpv_izva20160627-02.eaf
Handle URI: https://hdl.handle.net/1839/EF58E573-438A-4425-A837-16C8F7F3C79B
Internal Node ID: MPI2274086#
Node type: Written Resource
Format: text/x-eaf+xml
File size: 10114 bytes
Last modified: Sat Dec 03 18:51:21 CET 2016
MD5 Check sum: unknown
Access Info
The resource can be viewed by clicking the "view" butt
permissions.
General Accessibility: Access to t
Currently accessible to user anonymous: no
Applicable License Agreement(s)
No licenses required for this resource.
Rights
All resources in this archive are Copyright © of their re
permission of the copyright holder is prohibited, unless
contact information or contact corpman@mpi.nl.
- Main archival versions in TLA
- Still being updated
- Serves primarily as a long-term storage
- Data available upon request
- Handles get assigned in the upload process, etc.
- Contains also good search tool, TROVA
- Metadata gets indexed
- Not impossible to maintain …
… but clicky!
- Clicking hundreds of times makes updating tedious and error-prone

**Substring Search** | **Single Layer Search** | **Multiple Layer Search**

**Types:** ☑ **EAF (498)** ☑ **Text (9)** ☑ **HTML (1)**

**Domai...** Permic Varieties

**Find** köp

**Ready** Found 891 hits in 852 annotations

Action: **Show Concordance View** Page: **<...** **<** **>** **>..** Hit 1 - 15 of 891 hits

Context Size: **4** Font: **Lucida Grande** **12** ☐ Show Info Balloons

*но татӧн сійӧ яранъяс из вӧв* нӧшта и **кӧр** видзысьӧсь *татӧн кӧръяссӧ видзӧны коркӧ дажӧ приколхозӧ видзисны а сейсятпервӧй годах ме помнита кӧр н*

*но татӧн сійӧ яранъяс из вӧв нӧшта и кӧр видзысьӧсь* татӧн **кӧр**ъяссӧ видзӧны коркӧ *дажӧ приколхозӧ видзисны а сейсятпервӧй годах ме помнита кӧр на вӧлі сейсетьпервый г*

*кӧр видзысьӧсь татӧн кӧръяссӧ видзӧны коркӧ дажӧ приколхозӧ видзисны а* сейсятпервӧй годах ме помнита **кӧр** на вӧлі *сейсетьпервый годах на кӧр на миян татын вӧлі именна важгортсаысь??? о-о-о тундраа из ветлыны най*

*ӧны коркӧ дажӧ приколхозӧ видзисны а сейсятпервӧй годах ме помнита кӧр на вӧлі* сейсетьпервый годах на **кӧр** на миян татын вӧлі *именна важгортсаысь??? о-о-о тундраа из ветлыны найӧста татын и олісны*

*а тані кыдзи тані яран, тані яранъяс тшӧтш вӧйтти вӧлісны? мм да вӧлі?* а **кӧр**ъяс кыдз, кӧні видзисны, вӧрын?

*вӧйтти яранъяс татi ветлӧмаӧсь* **кӧр**ъясӧн *а миян тані Важгортас асланым яранъяс вӧліны кӧръяссӧ, кӧръяссӧ видзисны приколхозӧ тан миян видзис*

*вӧйтти яранъяс татi ветлӧмаӧсь кӧръясӧн а миян тані Важгортас асланым яранъяс вӧліны* **кӧр**ъяссӧ, кӧръяссӧ видзисны *приколхозӧ тан миян видзисны кӧръяссӧ вӧлі вӧлі вӧлі вӧлі вӧлі вӧлі ме сэйсятьпятӧй*

*вӧйтти яранъяс татi ветлӧмаӧсь кӧръясӧн а миян тані Важгортас асланым яранъяс вӧліны* кӧръяссӧ, **кӧр**ъяссӧ видзисны *приколхозӧ тан миян видзисны кӧръяссӧ вӧлі вӧлі вӧлі вӧлі вӧлі вӧлі ме сэйсятьпятӧй годын вӧл*

*ін а миян тані Важгортас асланым яранъяс вӧліны кӧръяссӧ, кӧръяссӧ видзисны* приколхозӧ тан миян видзисны **кӧр**ъяссӧ *вӧлі вӧлі вӧлі вӧлі вӧлі вӧлі ме сэйсятьпятӧй годын вӧлӧм таысь муӧна сісьэдз*

*яранъяс да* **кӧр** видзӧмаӧсь, кӧръяссӧ *миян тожӧ овлывл- ??? вӧр сюра ягын шуасны сійӧс*

*яранъяс да* кӧр видзӧмаӧсь, **кӧр**ъяссӧ *миян тожӧ овлывл- ??? вӧр сюра ягын шуасны сійӧс*

*из вӧв нӧшта и* **кӧр** *видзысьӧсь татӧн кӧръяссӧ видзӧны*

*и кӧр видзысьӧсь татӧн* **кӧр**ъяссӧ *видзӧны коркӧ дажӧ приколхозӧ*

*сейсятпервӧй годах ме помнита* **кӧр** *на вӧлі сейсетьпервый годах*

*вӧлі сейсетьпервый годах на* **кӧр** *на миян татын вӧлі*

## Video display

min

No streaming media available

## Information

min

General | Session | Technical

Resource: kpv_udo20130804Bda...
Media file: none
Elapsed time: 00:01:49:858

Selected chunk:
Begin time: 00:01:49:858
End time: 00:01:51:746
Text: –

## Mini Data Frame

min

Tier | Comments

но татӧн сійӧ яранъяс из вӧв нӧшта и кӧр видзысьӧсь татӧн кӧръяссӧ видзӧны коркӧ дажӧ приколхозӧ видзисны а сейсятпервӧй годах ме помнита кӧр на вӧлі сейсетьпервый годах на кӧр на миян татын вӧлі именна важгортсаысь??? о-о-о тундраа из ветлыны найӧста татын и олісны

Tier: orth@VFL-M-1949

Font size: 14

Play selection
Clear selection
Create bookmark

|< >|
<< >>
< >
+ -

Play screen by screen
Play continually

Tier text font: Lucida Grande

## Timeline

Comments overlay

ref@NTP-M-19
ref@IMS-M-19
ref@VVJ-F-19
ref@JSM-M-19
ft-fin@VFL-M-
orth@VFL-M-1 ӧр видзысьӧсь | татӧн кӧръяссӧ видзӧны коркӧ | дажӧ приколхозӧ видзисны | а
ft-fin@NTP-M-
orth@NTP-M-1 мм | да
ft-fin@IMS-M-
orth@IMS-M-1 кӧръяссӧ, кӧръяссӧ видзисны | приколхозӧ тан миян видзисны кӧръяссӧ
ft-fin@VVJ-F-1
orth@VVJ-F-19
ft-fin@JSM-M-
orth@JSM-M-1
word@VFL-M- кӧр | видзы | татӧн | кӧръяссӧ | видзӧны | коркӧ | дажӧ | приколхозӧ | видзисны | а
word@IMS-M- кӧръяссӧ, | кӧръяссӧ | видзисны | приколхоз | тан | миян | видзисны | кӧръяссӧ
word@VVJ-F-1
word@JSM-M-

# Александр Юрьевич Терентьев

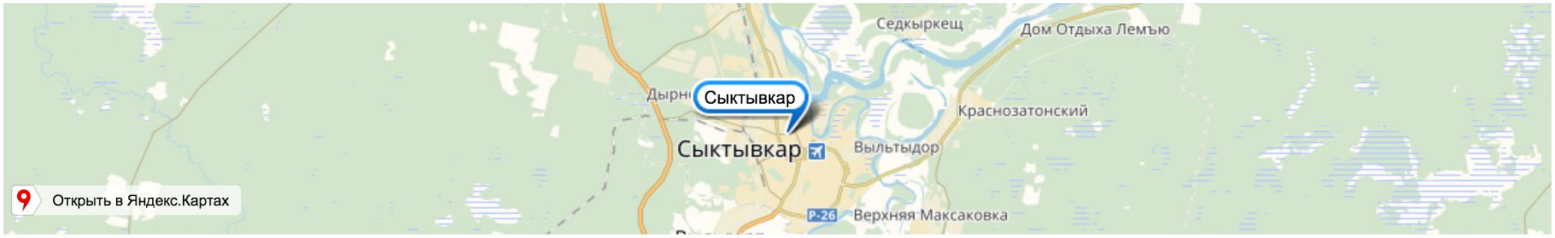


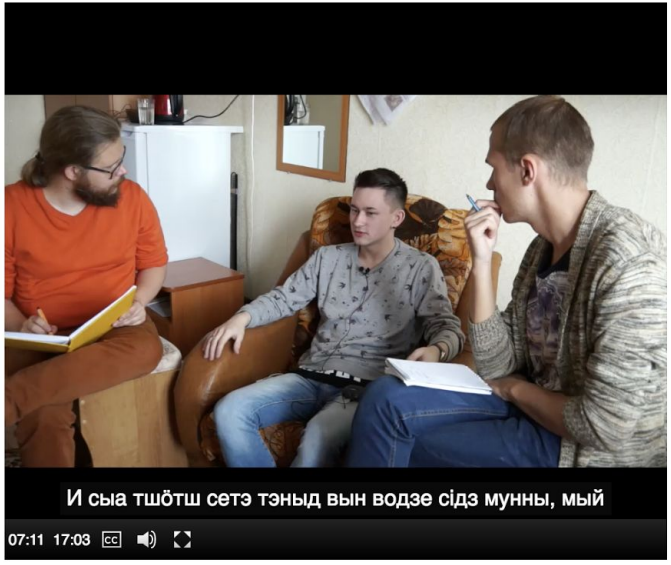


AJT-M-1992(00:07:10 - 00:07:14)

KPV: И сыа тшӧтш сетэ тэныд вын водзе сідз мунны, мый

RUS: И это тоже дает тебе силы двигаться дальше, что

ENG: And it also gives you strenghts to go further, that

AJT-M-1992(00:07:14 - 00:07:17)

KPV: мӧдъяс велэдэны, а мыля ми асьнум асьнумес ог велэдэ,

RUS: другие изучают, а почему мы сами себя не изучаем,

ENG: others study, and why we ourselves don't study ourselves,

AJT-M-1992(00:07:17 - 00:07:19)

KPV: колэ тшӧтш сіе вӧчны.

RUS: это тоже надо делать.

**Show Timeline**

Report errors

Räätälöity CQP-haku: Lataa CQP-ohjeet

```
[word = "kissa"]
```

Etsi | virkkeen | sisältä

korp.csc.fi

Konkordanssi: osumia sivulla: 25 | järjestä korpuksen sisällä: järjestämätön | Tilastoja: laske tilastot tämän perusteella: sana | Näytä sanakuva | Näytä kartta

Konkordanssi | Tilastoja | Sanakuva | Kartta | Nimiluokittelu

Tuloksia: 48

« ‹ 1 2 › » Siirry sivulle / 2 Näytä konteksti

FinnTreeBank 3: EuroParl

| | | |
|---|---|---|
| Kysymme, tiedätkö, mikä | kissa | on, ja vastaus on: kissa on tiikeri, joka on neuvotellut valtiovarainvaliokunnan kanssa. |
| Kysymme, tiedätkö, mikä kissa on, ja vastaus on: | kissa | on tiikeri, joka on neuvotellut valtiovarainvaliokunnan kanssa. |
| Olen myös vakuuttunut siitä, että teidän on oltava vihdoin rohkea ja nostettava | kissa | pöydälle. |
| Meidän on lakattava kiertämästä asioita kuin | kissa | kuumaa puuroa ja nostettava vihdoinkin esiin todelliset ongelmat, jotka liittyvät apartheidin jälkei |
| Eyadéma leikkii kanssamme | kissa | ja hiirtä. |
| Tämä olisi tae sekä Yhdysvalloille että Irakille, ja se estäisi | kissa | ja hiiri -leikit. |
| Arvoisa puhemies, uskoakseni me leikimme nyt | kissa | ja hiiri -leikkiä parlamentissa ja tämä on kamalaa, aivan kamalaa demokratian kannalta! |
| n aseistariisunnan puolesta, ei ole epäilystäkään siitä, että eikö Saddam Hussein jatkaisi entiseen tapaan | kissa | ja hiiri -leikkiään YK:n kanssa loputtomiin. |
| Meidän on aika toimia IMO:ssa yhdessä ja vaatia loppua tällaiselle | kissa | ja hiiri -leikille, jollaiseksi kansainvälinen merenkulku näyttää muuttuneen. |
| Varsinkin turvastandardimietinnön valmistelu on ollut aika ajoin melkoista | kissa | ja hiiri -leikkiä komission ja neuvoston kanssa. |
| Muuten saattaa syntyä kuva, että Dov Weisglass oli oikeassa ja hänen ainoa virheensä oli nostaa | kissa | pöydälle. |
| Kiinan tapauksessa ongelmaa ei kuitenkaan voida kiertää kuin | kissa | kuumaa puuroa. |
| lexander, eurooppalaiset ansaitsevat enemmän kuin unionin puheenjohtajavaltion ja sen 24 kumppanin | kissa | ja hiiri -leikin unionin tulevaisuuden kannalta merkittävän Eurooppa-neuvoston kokouksen aatton |
| nnitetä huomiota kalavaroihin, on sama kuin täyttäisi kultakalamaljan puhtaalla vedellä vasta sitten, kun | kissa | on jo ehtinyt napata ja syödä kultakalan. |
| skirjan " hyödyntäminen olennaisena osana " Euroopan perustuslakia " on ollut juonena jo pitkään tässä | kissa | ja hiiri -leikissä. |
| attomat kuluttajat voivat ostaa leluja lapsilleen hyväuskoisina ja aavistamatta lainkaan, että esimerkiksi | kissa | on voitu nylkeä elävältä käytettäväksi samaisessa lelussa. |
| sanonnoille, kuten de hond in de pot vinden ( keksiä koirasta illallinen ) tai de kat in de zak kopen ( ostaa | kissa | säkissä ), se tarkoittaa, että haluamme suojella meille rakkaita eläimiä emmekä voi hyväksyä, että |
| ttävä skottilaisen - joskaan ei poliittisen - kollegani Struan Stevensonin näkemykseen toteamalla, että se | kissa | , joka olisi nostettava pöydälle, ovat ne huonot hinnat, joita maanviljelijät joutuvat yhä sietämään, |
| Emme saa enää sallia tämän | kissa | ja hiiri -leikin jatkumista. |
| Kuten Deng Xiaopingilla oli tapana sanoa: " Ei ole väliä, onko | kissa | musta vai valkoinen, kunhan se pyydystää hiiriä ". |
| Toisinaan on erittäin vaikea nähdä, kuka tässä | kissa | ja hiiri -leikissä on kissa ja kuka hiiri. |
| Toisinaan on erittäin vaikea nähdä, kuka tässä kissa ja hiiri -leikissä on | kissa | ja kuka hiiri. |
| Kriisistä ei päästä yli siten, että laitetaan | kissa | vahtimaan kerma-astiaa! |
| e, että on harhaa uskoa, että tähän yhteyteen sopii hyvin satu Bremenin soittoniekoista, jossa aasi, koira, | kissa | ja kukko lähtivät suureen maailmaan, koska he uskoivat, että missä tahansa on jotakin parempaa k |
| Yhdysvallat pitää sitten hauskaa meidän kustannuksellamme niin kuin | kissa | hiiren kanssa: se valittaa Maailman kauppajärjestöön viljatuotteista ja riisistä, ja kun komissio aiko |

« ‹ 1 2 › » Siirry sivulle / 2

Lataa tiedostona muodossa: Annot Ref Nooj Rows

**Korpus**

FinnTreeBank 3: EuroParl

Kuvailutiedot
Lisenssi: CC BY 3.0 (CLARIN PUB)
Viittaa korpukseen
Linkki korpukseen Korpissa: urn:nbn:fi:lb-201406021

**Tekstin ominaisuudet**

tiedoston nimi: EuroParl Corpus/fi-en/fi/ep-00-07-04.txt
luvun otsikko: Vastuuvapaus 1998
puhuja: Camre
alkuperäiskieli: tuntematon
rivinumero: 338

**Sanan ominaisuudet**

perusmuoto: kissa
perusmuoto (yhdyssanarajat): kissa
sanaluokka: substantiivi
morfologinen analyysi: N Nom Sg
dependenssisuhde: subjekti

Näytä dependenssipuu

# Archive interaction (in an ideal world)

- New audio and video files added roughly once a year
- Once audio and video are archived, changes to those are exceptional

- There is continuous work going on with annotations
- We use version control (Git) to keep them organized
  - Changes every few days
  - There are usually several larger changes being done

- Ideally the new changed files would be updated in the archive regularly
  - Every half a year?
  - Would correspond to a change in corpus version number

# Workflow scheme

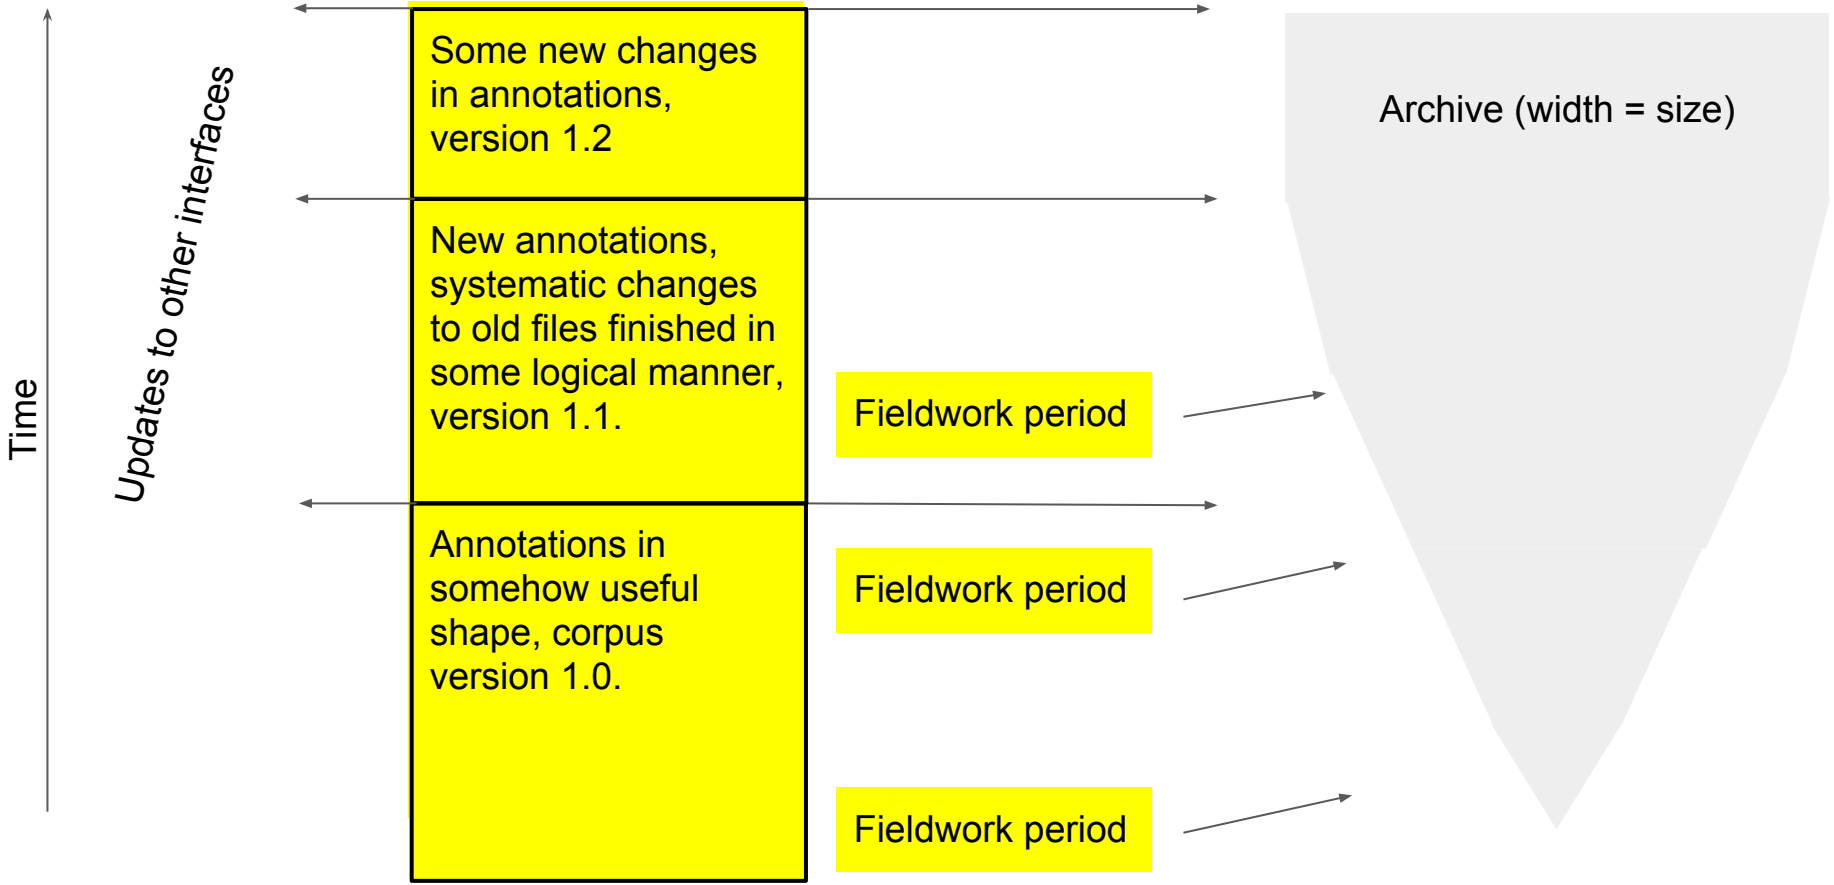

# Dreaming of API

- At the moment we mainly interact with the archive through specific software
  - Arbil, LAMUS2, etc.
- Works, but is built around the idea that user want to manually do every edit
- We know exactly which files have to be changed and their location in the tree
  - So why do we have to select manually these things again in the interface?
- **Are archives generally even interested about offering APIs to their data?**

- The tasks we need to do are rather modest:
  - Add a file, update a file
  - Change the access level
  - Get information about the files
    - Handles, date of change, MD5, information about number of times accessed, etc.

- Data in different interfaces has to be the same!

# Thank you!

This work was partially supported by the LATTICE laboratory through a RGNF-CNRS grant.
The research on Iźva Komi has been funded by Kone Foundation.